

不偏分散は、どうして $n - 1$ で割るの？ *

浜田 宏

登場人物

あおば

青葉: 大学生。数学が苦手

かきょういん

花京院: 大学生。数学が好き。スタンドは使えない。

花京院は作業机の隅で、本を読んでいる。

広い机の上には、論文のコピーと計算用紙が散乱している。

青葉は授業課題のレポートを書くために、パソコンのモニタに向かっている。

数理行動科学研究室の分析室には、青葉と花京院の 2 人だけがいた。

「ねえ、花京院くん。いま時間ある？」花京院の読書が一段落したのを見計らって、青葉は声をかけた。

「うん、まあ暇と言えど暇だし、暇でないとと言えば暇じゃない」花京院は、壁の時計で時間を確認した。

「どっちなのよ」

「ごめん、ちょっと気取ってみただけで、めちゃくちゃ暇だった。なに？」

* ver1.0., 2022 年 6 月 20 日; ver1.1., 7 月 20 日; ver1.2., 8 月 5 日 (推定量のバイアスと平均 2 乗誤差の区別を明確化した。この指摘について黒木玄さんに感謝します)

「えっとね、統計学の授業で《不偏分散》って、習ったでしょ……。よくわかんないから教えてほしいなと思って」

「不偏分散？ なにそれ」

「ほら、あの $n - 1$ で割るやつだよ」

「ああ、この推定量のことかな」

花京院は机のうえの計算用紙に式を書いた。

$$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

「そうそう。これこれ」

「これ、不偏分散っていう名前なんだ」と花京院がつぶやく。

「いま自分で式を書いたじゃん。名前覚えてないの？」青葉が聞いた。

「うーん、式はなんとなく覚えてるけど、名前まで覚えてなかった」

「この式って、すごく変じゃない？」

「30 分」

「え？」

「ちゃんと説明するのに、30 分」

そう言うとき花京院はパソコンの前に座ると、キーボードをたたき始めた。

1 青葉の疑問

「君は不偏分散のどこが変だと思うの？」

「えーっとね、 n 個の項を足してるのに、 $n - 1$ で割るところ」

「そうだね。おかしいね」

「でしょ？ 花京院君だって、おかしいと思うでしょ？」

「そうだね。最初に見たときは、なんでだろうと思ったよ。でもそれを使う目的と理由を考えたら納得したよ」

「理由があるんだ」

「ちゃんと目的と理由があるんだよ。実験して確かめてみよう」

「実験？」

花京院は、キーボードでなにやら謎のコードを書くと、ヒストグラムを一つ画面に描いた。




図1 全体の分布

「これをね、観察する対象の《全体》としよう。1000 個の数値をヒストグラムにまとめたものだよ」

「へえー。なんのデータなの？」

「いや、特に意味はないよ。コンピュータで適当に作ったから」

「なにか意味がないと、イメージ湧かないよー」

「しょうがないな。じゃあ柿ピー」

「え？」

「大体 0~120 くらいで分布しているから、1 日に食べる柿ピーのグラム数ってことにしよう。柿ピーの小袋って 30g なんだよ」花京院は机のうえに置いてあったお菓子の袋をひとつ手に取った。

「わかった。じゃあこれは《1 日に食べる柿ピーのグラム数》のデータだね」

「そういうこと。この 1000 人は M 町に住む成人男性全員の数としよう。全員ってところが重要だよ。この《全体》のデータからまず平均値を計算してみよう。1000 人分のデータを

$$x_1, x_2, \dots, x_{1000}$$

で表すと、その平均は

$$\frac{x_1 + x_2 + \cdots + x_{1000}}{1000} = \frac{1}{1000} \sum_{i=1}^{1000} x_i$$

で計算できる。実際に計算してみると 31.91 だから、1 人平均 32g ほど柿ピーを食べることが分かる。」

「意外と少ないんだね。私なら 2 袋はいけるよ」

「もちろん、そういう人もいるだろう。そういう食べる量の《バラつき》を表す統計量が分散だったね。《全体》データから分散を計算してみよう。さきほど計算した平均値を μ とおけば分散は

$$\frac{(x_1 - \mu)^2 + (x_2 - \mu)^2 + \cdots + (x_{1000} - \mu)^2}{1000} = \frac{1}{1000} \sum_{i=1}^{1000} (x_i - \mu)^2$$

となる。計算した結果は 1287.11 だよ」

「これは n で割ったね」

「そう。いま計算したのは《全体》の分散。これを《母集団》の分散ともいう。もし観察対象全てのデータが手元にあるのなら、分散を計算するときただ n で割ればいい」

「うん。それは分かった。じゃあ、いつ $n-1$ で割るの？」

「標本から《全体》の分散を推定して、その推定値の平均を《全体》の分散に近づけたときだよ」

「ちょっとなに言ってるかわからない」

「実例で示そう」

2 標本をつかった推定

「いま《全体》から 20 個だけデータをランダムに抜き出したとしよう。たとえばこんな感じ」

65.06, 11.44, 13.08, ..., 145.86

「うん」

「省略して書いたけど、いまここに 20 個の数値がある。この 20 個を使って平均値を計算してみよう。全部足して 20 で割るだけだよ。結果は

$$\frac{65.06 + 11.44 + 13.08 + \cdots + 145.86}{20} = 28.46$$

だよ。20 個取り出して平均をとったから一般的な式で書くと

$$\frac{x_1 + x_2 + \cdots + x_{20}}{20} = 28.46$$

となる。これは標本の平均値で、記号で \bar{x} と書くことにしよう。ここまではいいかな？」

「うん、まあ平均値の計算くらい分かるよ」

「さらにこの標本平均値を使って、標本のちらばりを計算する。そして n と $n - 1$ で割った場合を比較してみよう。まず $n - 1$ で割る場合は

全ての値から標本平均値 28.46 を引いて 2 乗した数を全部足し、最後に 19 で割る。

という操作をする。こんな感じだ。

$$\frac{(65.06 - 28.46)^2 + (11.44 - 28.46)^2 + \cdots + (145.86 - 28.46)^2}{19} \\ = 1183.32$$

次に $n = 20$ で割る。

$$\frac{(65.06 - 28.46)^2 + (11.44 - 28.46)^2 + \cdots + (145.86 - 28.46)^2}{20} \\ = 1124.15$$

だね」

「うーん、計算方法は分かるよ。でもまあ、大体一緒じゃない。違いが分からない」

「 $n - 1$ で割った値と、 n で割った値を比べてみよう。どっちが《全体》の分散に近いかな？」

「えーっと、比べてみるね。

n で割った場合 : 1124.15
 $n - 1$ で割った場合 : 1183.32
《全体》の分散 : 1287.11

だから、 $n - 1$ で割った場合のほうが、《全体》の分散に近いよ」

「そのとおり。この実験の結果、標本から《全体》の分散を推測するときに、 n で割るより $n - 1$ で割った《不偏分散》を使うほうが、目的の値に近い値になった」

「まあそうだけど、いまのは偶然かもしれないじゃん」

青葉は怪しそうに計算結果を見比べた。

「いいねえ。その注意深さは大事だよ。じゃあ計算を繰り返して、推定値の平均と《全体》の分散の近さを確かめてみよう。手続きはこうだよ」

1. 《全体》から 20 個の標本を抜き出す
2. 標本から《全体》の分散に対する「 n で割る推定値」と「 $n - 1$ で割る推定値」を計算する
3. この操作を 100 回繰り返し、それぞれの推定値を 100 個ずつ記録する
4. それぞれの推定値 100 個から 2 種類の平均（「 n で割った場合の推定値 100 個の平均」と「 $n - 1$ で割った場合の推定値 100 個の平均」）を求める
5. どちらの平均が目的の「《全体》の分散」に近いかを比較する

「いいかな？」

「OK」

「それじゃあ計算するよ。100 回ほど標本抽出と計算を繰り返してみよう」花京院は、計算用のコードを書き足した。




図2 n で割った場合の結果

「まずこれが n で割った場合。100 回分の計算結果のヒストグラムだ。
点線の位置が本当の値（《全体》の分散）だよ」

「うーん、まあ微妙だね」

「次いこう」




図3 $n - 1$ で割った場合の結果

「これが $n - 1$ で割った場合」

「うーん、これも結構ズレてるね」

「二つ並べてみよう」




図4 計算結果の比較。左が n 、右が $n - 1$ で割った場合の結果

「うーん、並べてもやっぱりわかんないや」

「ちょっと見た目では分からないね。2つの推定値の分布それぞれの平均を計算して、本当の値と比較してみよう

n で割った推定値の平均 : 1184.31

$n - 1$ で割った推定値の平均 : 1279.28

本当の値 : 1287.11

この結果を見ると、

標本から《全体》の分散を推測するとき、 $\dot{\bar{x}}$ の平均を本当の値に近づけたいなら、 n で割るより $n - 1$ で割った《不偏分散》を使うほうがよい

ことが分かる」

「確かにそうだね」

「ただしこの計算は、特定の目的に、不偏分散が適していることを示したにすぎない」

「どういうこと？」

「たとえば推定値の平均じゃなくて、推定値と目的の値のズレを

$$(\text{推定値} - \text{目的の値})^2$$

で定義して、この2乗誤差の平均を小さくしたいなら、別の推定量を

使ったほうがよい場合がある*1」

「へえ、そうなんだ」

「ここまでの数値計算で、 $n - 1$ で割る推定値を使う目的と理由は納得できた？」花京院が聞いた。

「うーん、ちょっと待ってよ。分かったような気もするんだけど……、まだなんかしっくりこないな」

青葉は計算結果を見比べながら、つぶやいた。

「どこが？」

「計算の結果がこうなることは分かったよ。でもどういえばいいのか……。どうしてそうなるのか、まだ分からない」

「ふむ」

「《全体》の分散を計算する式は

$$\frac{1}{1000} \sum_{i=1}^{1000} (x_i - \mu)^2$$

でしょ。標本を使って

$$\frac{1}{20} \sum_{i=1}^{20} (x_i - \bar{x})^2$$

っていう似たような式で推測すると、どうして平均がズレちゃうの？」

「そうだね。それも計算して確かめてみよう」

*1 推定量を Θ 、目的の値を θ とおくと $E[(\Theta - \theta)^2]$ は、推定量と目的値とのズレを表しています。この期待値（平均 2 乗誤差）は、推定量の分散とバイアス（推定量の期待値 $E[\Theta]$ と目的値 θ とのズレ）の 2 乗に分解できます（竹村 2020:123-125）。

$$E[(\Theta - \theta)^2] = V[\Theta] + (E[\Theta] - \theta)^2$$

バイアスをおさえる不偏化によって推定量自身の分散が大きくなる場合、平均 2 乗誤差が全体として大きくなることもあります。

3 確率変数で表す

「まず、先ほどの実験で確かめたことをまとめよう。標本を使って

$$\frac{1}{20} \sum_{i=1}^{20} (x_i - \bar{x})^2$$

と

$$\frac{1}{19} \sum_{i=1}^{20} (x_i - \bar{x})^2$$

という式で《全体》の分散を推定すると、19 で割ったほうが平均的に本当の値に近かった」

「そうだね」

「ここで標本として取り出した数値

$$x_1, x_2, \dots, x_n$$

は、観測するまで値が分からないけど、《全体》の中にある数値であることは決まっているという特徴に注目する」

「ふむふむ」

「このような特徴は、《確率変数》という道具で表すことができる」

「確率変数？」

「とりあえずサイコロを想像してほしい。サイコロは振るまで値が決まらないよね。標本も同じように観測するまでは、どの値になるかわからない。でも《全体》の中にある数値が出てくることは決まってるし、《全体》の中で観測しやすい数値は、やっぱり標本でも観測しやすい。そこで《全体》の分布を確率変数 X で表し、標本を

$$X_1, X_2, X_3, \dots, X_{20}$$

という 20 個の確率変数で表す」

「ちょっとなに言ってるかわからない」

「もう少し具体的に考えてみよう。《全体》データに記録された数値 1000 個が表面に刻印された 1000 面サイコロを想像する。全体からサイ

ズ 20 の標本をとりだす作業は、1000 面サイコロの出目を 20 回分記録することに対応する。その結果が

$$(x_1, x_2, \dots, x_{20}) = (3.28, 7.65, \dots, 11.09)$$

だとする。次に 20 回ふった結果が

$$(x_1, x_2, \dots, x_{20}) = (9.75, 2.12, \dots, 6.58)$$

だとする。

このように標本の実現値は観測するたびに異なる値がでてくる。

ただし全ての値は《全体》の中にある数値で、同じサイコロ X の実現値と見なすことができる。個々の具体的な実現値に対応するサイコロ振りの名前が

$$X_1, X_2, X_3, \dots, X_{20}$$

というわけ。以下大文字で確率変数、小文字で実現値を表すと決めておく。 x_1 は 1 回目のサイコロ振り X_1 の結果で、 x_{20} は 20 回目のサイコロ振り X_{20} の結果だよ」

「ふむ。サイコロに喩えるとちょっと分かってきた」

「標本から平均値を計算する式は

$$\frac{x_1 + x_2 + \dots + x_{20}}{20}$$

だった。このとき

X_1 というサイコロの目が x_1

X_2 というサイコロの目が x_2

\vdots

X_{20} というサイコロの目が x_n

という対応になっているので、確率変数を使えば

$$\frac{X_1 + X_2 + \dots + X_{20}}{20}$$

という抽象的な演算として表現できる。

この式は、《複数の確率変数を、しかじかの演算によって1つの確率変数として合成しますよ》という計算方法を示している。この操作を記号 \bar{X} で表すことにする。標本に含まれるデータ数を n とおけば

$$\frac{X_1 + X_2 + X_3 + \cdots + X_n}{n} = \bar{X}$$

だ。標本を使って計算するので《標本平均》と呼ばれることが多い。この《標本平均》は平均という名前がついているけど、

$$\frac{X_1 + X_2 + X_3 + \cdots + X_n}{n}$$

という、ひとかたまりで確率変数なんだよ。だから1つの定まった値じゃなくて、確率的にいろいろな値をとる。つまり分布をもっている」

「うーん、ややこしくなってきた。標本平均なのに1つの値じゃないって、どういうこと？」

「《全体》の平均値を考えてみよう。これは1つしか存在しない。1000個のデータを足して1000で割った数だから、必ず一つの定まった値となる。その値を記号 μ で表すと約束した」

「母平均って呼ばれるやつだね」

「でも \bar{X} は、 $X_1, X_2, X_3, \dots, X_{20}$ という標本の実現値によって、値が異なる。だから分布を持つ」

「なるほど。1回目にとりだした20個の値と、2回目にとりだした20個の値は違うから、 \bar{X} の実現値は毎回違う値になるんだ」

「そういうこと。」

$$\frac{X_1 + X_2 + X_3 + \cdots + X_n}{n} = \bar{X}$$

は、これ自体が確率変数だってことがポイントだよ」

4 確率変数としての不偏分散

「次に《標本平均（確率変数）》をつかい、《標本分散》を定義する。

$$\langle \text{標本分散} \rangle = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

これは君が自然だと考える推定量だ」

「そうそう。 n で割ってるから、こっちのほうが自然な気がする」

「一方、 $n - 1$ で割る不自然な推定量を《不偏分散》という名前で定義する」

$$\text{《不偏分散》} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

「うん。これは不自然だよな。どこから $n - 1$ が出てきたのか分からない」

「この《標本分散》や《不偏分散》は確率変数かな？ それともただの決まった数かな？」

「うーん、どっちかな。 \bar{X} は確率変数だったけど、それをさらに足し合わせるとどうなるのかな」青葉は首をかしげた。

「じゃあ、ヒントを出そう。かく……」

「かく？」

「り…… つ……」

「りっ？」

「へん…… す……」

「確率変数？ ヒントの出しかた下手すぎなんですけど」

「確率変数同士を足すと、その結果も確率変数になるんだよ。これで準備は整った。先ほど僕らが実験でやった計算は、

$$\text{標本分散} : \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

や

$$\text{不偏分散} : \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

という確率変数の期待値を近似的に求める作業に対応している。期待値とは確率変数の平均のことだよ。実際に《標本分散》という確率変数の期待値を計算してみよう」

一般的に、確率変数 X の期待値を

$$E[X] = \sum_{i=1}^m P(X = x_i)x_i \quad \text{離散的な場合}$$

$$E[X] = \int_{-\infty}^{\infty} xf(x)dx \quad \text{連続的な場合}$$

と定義する*2。

《全体》のデータは1000個あるから、その期待値は

$$E[X] = \sum_{i=1}^{1000} P(X = x_i)x_i$$

で

$$P(X = x_i) = \frac{1}{1000}$$

だから

$$E[X] = \sum_{i=1}^{1000} P(X = x_i)x_i = \sum_{i=1}^{1000} \frac{1}{1000}x_i = \frac{1}{1000} \sum_{i=1}^{1000} x_i$$

となり、「《全体》に対応する確率変数 X の期待値」と「《全体》の平均値」は、完全に一致することがわかる。

次に確率変数 X の分散の定義を

$$V[X] = E[(X - E[X])^2]$$

とする。

以下では《全体》を表す確率変数 X の平均と分散を具体的に

$$\begin{aligned} E[X] &= \mu \\ V[X] &= \sigma^2 \end{aligned}$$

とおく。また標本 X_1, X_2, \dots, X_n は X と同一であり、独立であるとする。これは同じサイコロを振る操作を想像すれば自然な仮定だね。

次にいくつか補題を導入するよ。補題は証明の論理構造を明確にするための命題だよ。

*2 $\sum_{i=1}^m P(X = x_i) = 1$ を仮定します。 x_1, x_2, \dots, x_m は、全ての実現値を表しています

補題 1.

$$E[X^2] = V[X] + E[X]^2$$

証明.

$$\begin{aligned} V[X] &= E[(X - E[X])^2] \\ &= E[X^2 - 2XE[X] + E[X]^2] && \text{展開する} \\ &= E[X^2] - E[2XE[X]] + E[E[X]^2] && \text{期待値を分解する} \\ &= E[X^2] - 2E[X]E[X] + E[X]^2 && \text{定数を期待値の外に出す} \\ &= E[X^2] - E[X]^2 && \text{まとめる} \end{aligned}$$

言い換えると

$$E[X^2] = V[X] + E[X]^2$$

□

補題 2.

$$E[\bar{X}^2] = \frac{1}{n}V[X] + E[X]^2$$

証明. 補題 1 の X を \bar{X} に置き換える。

$$E[\bar{X}^2] = V[\bar{X}] + E[\bar{X}]^2$$

次に

$$\begin{aligned} V[\bar{X}] &= V\left[\frac{X_1 + X_2 + \cdots + X_n}{n}\right] \\ &= \frac{1}{n^2}V[X_1 + X_2 + \cdots + X_n] \\ &= \frac{1}{n^2}\{V[X_1] + V[X_2] + \cdots + V[X_n]\} \\ &= \frac{1}{n^2}nV[X] = \frac{1}{n}V[X] \end{aligned}$$

および

$$E[\bar{X}] = E\left[\frac{X_1 + X_2 + \cdots + X_n}{n}\right]$$

$$\begin{aligned}
&= \frac{1}{n} E[X_1 + X_2 + \cdots + X_n] \\
&= \frac{1}{n} \{E[X_1] + E[X_2] + \cdots + E[X_n]\} \\
&= \frac{1}{n} n E[X] = E[X]
\end{aligned}$$

より

$$E[\bar{X}^2] = V[\bar{X}] + E[\bar{X}]^2 = \frac{1}{n} V[X] + E[X]^2$$

□

これで準備は整った。あとは《標本分散》の期待値を変形していけば証明完了だよ。

$$E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n} E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right]$$

だから

$$E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right]$$

の部分を実に計算するよ。

$$\begin{aligned}
E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] &= E\left[\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right] \\
&= E\left[\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + \sum_{i=1}^n \bar{X}^2\right] && \text{総和をばらす} \\
&= E\left[\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right] && \text{総和の計算} \\
&= E\left[\sum_{i=1}^n X_i^2 - n\bar{X}^2\right] && \text{まとめる} \\
&= E\left[\sum_{i=1}^n X_i^2\right] - nE[\bar{X}^2] && \text{期待値を分解する} \\
&= \sum_{i=1}^n E[X_i^2] - nE[\bar{X}^2] && \text{期待値を分解する}
\end{aligned}$$

$$\begin{aligned}
&= nE[X^2] - nE[\bar{X}^2] && X_i = X \text{ を適用} \\
&= n(V[X] + E[X]^2) - nE[\bar{X}^2] && \text{補題 1 を適用} \\
&= n(V[X] + E[X]^2) - n\left(\frac{1}{n}V[X] + E[X]^2\right) && \text{補題 2 を適用} \\
&= n(V[X] + E[X]^2) - (V[X] + nE[X]^2) \\
&= nV[X] - V[X] = (n-1)V[X] && \text{計算する} \\
&= (n-1)\sigma^2 && \text{仮定より}
\end{aligned}$$

まとめると、

$$E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = (n-1)\sigma^2$$

であることが分かった。この結果、《標本分散》の期待値は

$$\begin{aligned}
E\left[\frac{1}{n}\sum_{i=1}^n (X_i - \bar{X})^2\right] &= \frac{1}{n}E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] \\
&= \frac{1}{n}(n-1)\sigma^2 \\
&= \frac{n-1}{n}\sigma^2
\end{aligned}$$

となることが分かる。

「あれ、なんか変な値になった」青葉が結果を見てつぶやいた。

「 n で割る自然な《標本分散》の期待値は

$$E\left[\frac{1}{n}\sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{n-1}{n}\sigma^2 < \sigma^2$$

だから、必ず《全体》の分散 σ^2 よりも小さいんだよ」

「ほんとだ」

「推定量の平均値をピッタリ σ^2 に合わせるには、どうしたらいいと思う？」と花京院が質問した。

「うーん、どうすればいいんだろ」青葉は首をひねった。

「《標本分散》の期待値に $n/(n-1)$ をかけてみよう。ここがおもしろいところだよ」

$$\begin{aligned}
E \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right] &= \frac{n-1}{n} \sigma^2 \\
\left(\frac{n}{n-1} \right) E \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right] &= \frac{n-1}{n} \sigma^2 \left(\frac{n}{n-1} \right) \\
E \left[\left(\frac{n}{n-1} \right) \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right] &= \frac{n-1}{n} \left(\frac{n}{n-1} \right) \sigma^2 \\
E \left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right] &= \sigma^2
\end{aligned}$$

「あ、ピッタリ σ^2 になった」

「左辺は、どういう確率変数の期待値かな？」

「えーと左辺は

$$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

っていう確率変数だね。これ、 $n-1$ で割ってるよ。……つまり、《不偏分散》だ」

「そのとおり。不偏分散（確率変数）の期待値は《全体》の分散 σ^2 と一致する。つまり自然な《標本分散 $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 》を使って全体の分散を推定すると、推定値の平均は目的値に一致しない。平均を目的値に一致させるには、推定量を《不偏分散 $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 》に修正する必要がある。これが n で割ると推定値の平均と目的の値がズレるけど、 $n-1$ で割ると一致する理由だよ。

さきほどの実験結果は

n で割った推定値の平均 : 1184.31

$n-1$ で割った推定値の平均 : 1279.28

本当の値 : 1287.11

だから、たしかに n で割った推定量の平均は $n-1$ で割った推定量の平均より小さくなっている」

「なるほどー」

「不偏分散のように、期待値が推定の目標である数値と一致する推定量

を不偏推定量っていうんだよ。ちなみに不偏だからといって、よい推定量とは限らない。有効性と言って……」

「それはまた今度でいいよ」しゃべり続ける花京院を青葉がさえぎった。

「OK。ちょうど 30 分だし、このへんで説明を終わろう。じゃあ柿ピーでも食べようか」

花京院は柿の種の小袋を一つ開封した。

まとめ

Q 不偏分散はどうして $n - 1$ で割るの？

A $n - 1$ で割る推定量を使うと、その期待値が《全体》の分散と一致するからです。

- パラメータの推定に用いる確率変数（の関数）を推定量といいます。特に期待値が目的の数値と一致する推定量を不偏推定量と言います。
- 標本平均 $\frac{1}{n} \sum_{i=1}^n X_i$ や不偏分散 $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ は不偏推定量の一種です。
- 確率変数（不偏推定量）としての不偏分散は分布を持っています。標本のデータから計算した具体的な不偏推定値は、不偏推定量の実現値と考えることができます。

参考文献

竹村彰通.2020.『新装改訂版 現代数理統計学』学術図書出版.